Predicción de Commodities usando series temporales

Universidad del Valle de Guatemala
Ciencia de Datos, sección 10
Castellanos, I; Pérez, M.; Rodríguez R. y Toledo, K.

Introducción

Debido a que el conjunto de datos se trata de commodities y estos son conocidos por su alta volatilidad, un modelo de volatilidad puede ser una opción viable para realizar predicciones (Mohommad y cía; 2023).

Para estos modelos suele recomendarse hacer transformaciones logarítmicas y medir la media, mediana, desviación estándar, curtosis, sesgo, autocorrelación y heterocedasticidad (De Jesús-Gutiérrez, 2023).

La generalización del caso multivariado de los modelos de volatilidad condicional (GARCH) univariados se usa para analizar la interrelación de las volatilidades de los mercados financieros. Este modelo, enfrenta la maldición de la dimensión, ya que el número de parámetros crece más rápidamente que el número de variables en el modelo. Además, requiere que la matriz de varianzas–covarianzas sea definida positiva (López, Ortiz y Cabello, 2009).

En el análisis exploratorio es importante estudiar las relaciones entre los retornos de distintos commodities, porque algunos mercados incorporan información antes que otros. Estas relaciones permiten evaluar si los movimientos pasados de un commodity contienen información para anticipar el futuro de otro. Estas relaciones pueden aportar capacidad predictiva, especialmente entre commodities económicamente relacionados. Por esta razón conviene analizar correlaciones contemporáneas y rezagadas entre las series y si se mantienen estables a lo largo del tiempo (Li, y cía., 2021).

Los modelos SARIMA y SARFIMA pueden usarse para predecir precios de commodities cuando las series tienen dependencia temporal y patrones estacionales. SARIMA es uno de los modelos más usados para series temporales, mientras que SARFIMA permite una diferenciación fraccionaria, por lo que es apropiado cuando la influencia de observaciones pasadas disminuye lentamente en el tiempo. Debe comprobarse la estructura temporal de la serie, incluyendo estacionariedad, estacionalidad y autocorrelación mediante ACF y PACF. Además, después del ajuste, los residuos deben evaluarse para verificar ausencia de autocorrelación y heterocedasticidad, así como compatibilidad con el supuesto de normalidad. De esta forma, la selección entre SARIMA y SARFIMA depende principalmente

de si la persistencia observada puede explicarse mediante diferenciación convencional o requiere integración fraccionaria (Devianto y cía., 2024).

Planteamiento del problema

En los últimos años, los mercados financieros han experimentado niveles de volatilidad extremadamente muy alta generados principalmente por crisis financieras, como la crisis del 2008 o la Pandemia de Covid-19. Por ello, el modelado y predicción de la volatilidad en el corto y largo plazos han sido de principal de interés para los inversionistas y académicos debido a que la volatilidad manifiesta de diferentes formas y niveles en los mercados financieros (De Jesús-Gutiérrez, 2023).

Objetivos

Generar modelos predictivos para cada Commodity presente en el conjunto train.csv, mediante 3 tipos de modelos temporales.

Determinar la validez del mejor modelo para cada Commodity, mediante la evaluación de los supuestos estadísticos de modelo.

Cuantificar la pérdida de capacidad predictiva del mejor modelo, mediante la evolución del error predictivo a través del tiempo de predicción.

Descripción de los datos

El reto de Kaggle cuenta con tres conjuntos de datos.

- train: Este conjunto tiene datos relacionados a commodities a través de 1961 unidades de tiempo.
- train_labels: Este conjunto de datos consiste en los rendimientos logarítmicos de un instrumento financiero o en las diferencias entre un par de instrumentos financieros.
- target_pairs: Muestra cómo calcular las columnas del conjunto train_labels a partir de las columnas train.

Análisis exploratorio de datos

Cuadro 1: Cantidad de datos en los archivos.

Archivo	Filas	Columnas
train	1961	558
train_labels	1961	425
target_pairs	424	3

Note que los conjuntos train y train_labels están relacionados mediante las filas y que el número de filas de target_pairs está relacionado con el número de columnas de train_labels. En el cuaderno se verifica que estos se relacionan en cada una de sus entradas.

Cuadro 2: Cantidad de columnas por tipos de variables.

Archivo	Entero	Flotante	Object
train	1	557	0
train_labels	1	424	0
target_pairs	1	0	2

La gran mayoría de las columnas son flotantes, la variable entera de train y train_labels se deben al índice del conjunto de datos. Solo target_pairs tiene tipo object.

Cuadro 3: Valores faltantes en conjuntos originales.

Archivo	Columnas con valores faltantes	Máximo de valores faltantes	Mínimo de valores faltantes
train	519	1713	51
train_labels	422	370	86
target_pairs	0	0	0

Hay muchas columnas con valores faltantes, pero no todas son útiles para train_labels.

Cuadro 4: Valores faltantes en el archivo train, solo con las columnas útiles para predecir.

Columnas útiles	Columnas con valores faltantes	Máximo de valores faltantes	Mínimo de valores faltantes
106	73	116	51

De las columnas que son útiles, se tiene presencia de valores faltantes en la mayoría de éstas, pero la cantidad de valores faltantes máxima es mucho menor que en el conjunto original.

Cuadro 5: Cantidad de columnas que no cumplen con criterios estadísticos deseados, para conjuntos diferenciados provenientes de train preprocesado a escala logarítmica y solo con columnas útiles.

Criterio	Diferencia 1	Diferencia 2	Diferencia 3	Diferencia 4
Media 0	0	0	0	0
Mediana 0	0	0	0	0
Media y mediana cercanas	0	0	0	0
Sesgo bajo	0	3	8	10

Curtosis positiva	0	0	0	0
Desviación estándar positiva	7	1	0	0
Rango intercuartílico positiva	6	2	0	0

Cuadro 6: Cantidad de columnas que no cumplen con supuestos deseados, para conjuntos diferenciados provenientes de train preprocesado a escala logarítmica y solo con columnas útiles.

Criterio	Diferencia 1	Diferencia 2	Diferencia 3	Diferencia 4
Estacionariedad de media	1	1	2	2
Estacionariedad de varianza	106	106	106	106
Volatilidad a través del tiempo	0	0	0	0
Autocorrelación ACF	1	0	0	0
Autocorrelación PACF	1	0	0	0
Estacionalidad	86	96	101	88

Algunos supuestos no se cumplen en algunas columnas, pero al tener como candidatos a modelos de volatilidad y a SARIMA/SARFIMA tenemos la capacidad de generar buenos modelos, ya que los supuestos son distintos, ya que los de volatilidad se suelen usar cuando no hay estacionariedad en varianza.

Figura 1: Muestra del conjunto train.

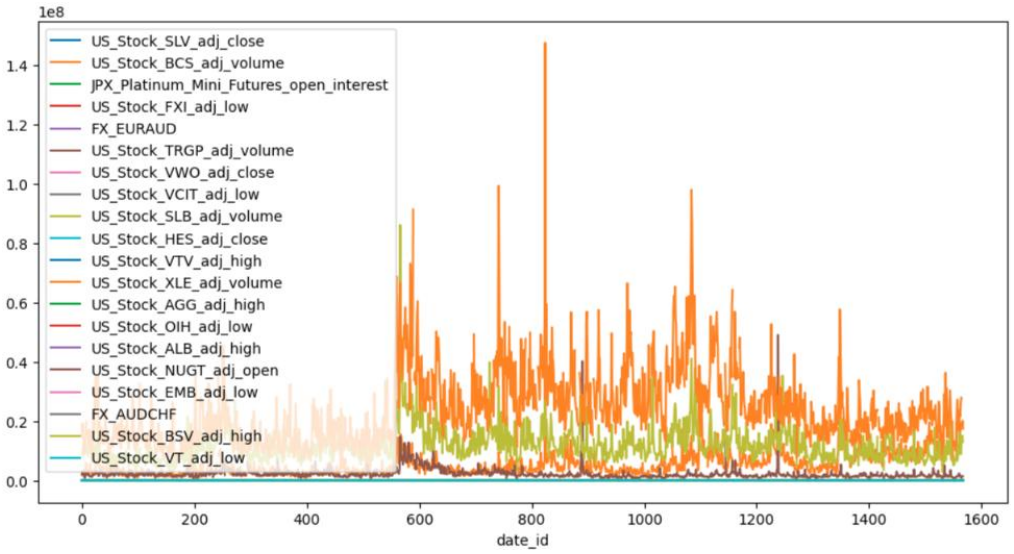


Figura 2: Muestra del conjunto train ajustado a escala logarítmica.

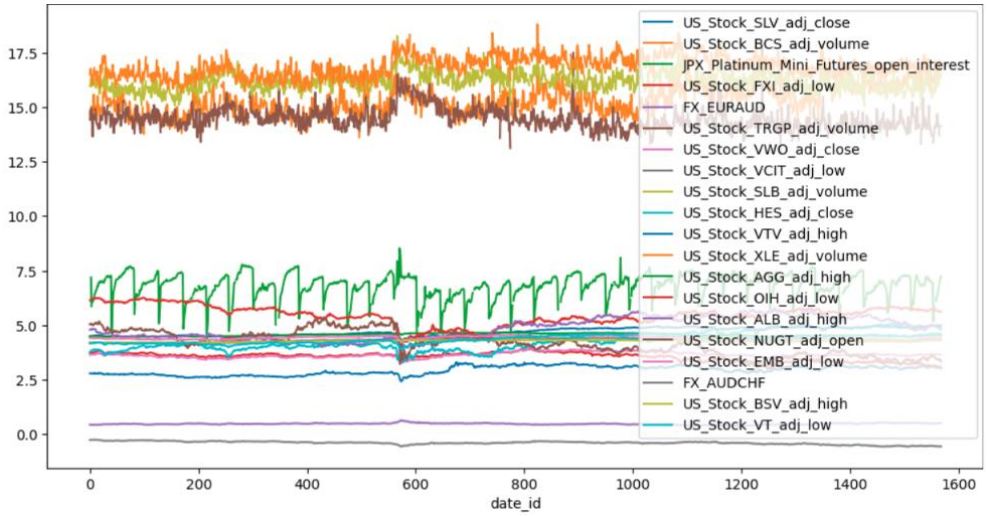
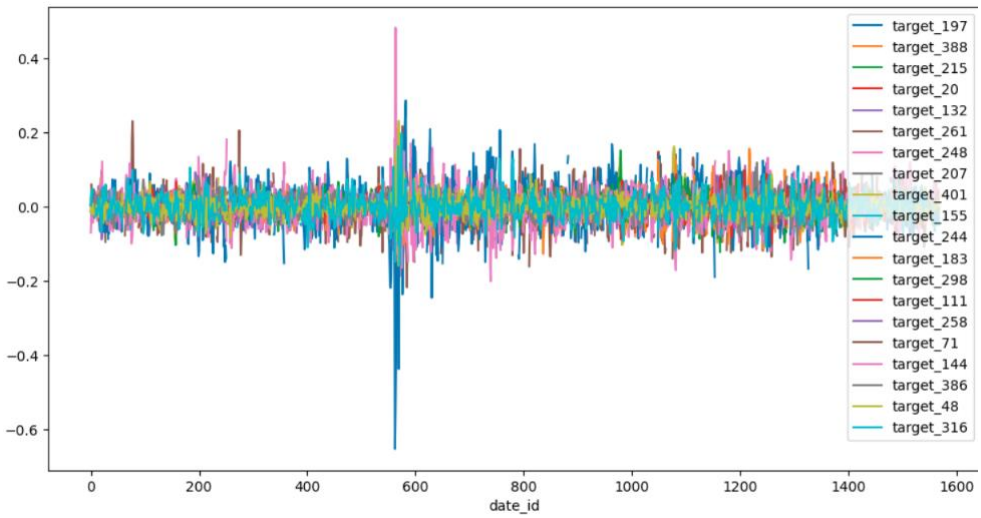


Figura 3: Muestra del conjunto train_labels.



Proceso de limpieza

- Se separaron únicamente las 106 columnas útiles, más el índice, en el conjunto train.
- Se aplicó la escala log al conjunto train.
- Se realizó el cálculo en las posiciones de train_labels con valores nulos, a partir de las posiciones correspondientes no nulas del conjunto train. En este paso se reemplazaron 66,977 valores nulos.

- Se reemplazaron los valores nulos que se encontraban en las primeras filas y últimas filas del conjunto train con el valor más próximo no nulo. En este paso se reemplazaron 36 valores nulos.
- Se reemplazaron los valores nulos que se encontraban en las primeras filas y últimas filas del conjunto train_labels con el valor más próximo no nulo. En este paso se reemplazaron 319 valores nulos.
- Se reemplazaron valores nulos del conjunto train mediante la interpolación, usando de extremos los valores no nulos que encerraban a los valores nulos. En este paso se reemplazaron 4,919 valores nulos y el conjunto quedó sin valores nulos.
- Se realizó el cálculo en las posiciones de train_labels con valores nulos, a partir de las posiciones correspondientes no nulas del conjunto train. En este paso se reemplazaron 20,107 valores nulos y el conjunto quedó sin valores nulos.

Conclusiones y recomendaciones

El conjunto train_labels es el resultado de una transformación logarítmica en el conjunto train y operaciones definidas por el conjunto target_pairs. Aunque hay algunos datos, que no pueden ser obtenidos, los cuales son los que pertenecen a las últimas filas, debido a que, al realizar operaciones con datos futuros, se requerirían de más filas en el conjunto train para generar todas las filas de train_labels.

De las 557 (sin contar el índice) variables del conjunto train, solo son útiles 106. Estas fueron definidas mediante la aparición en el conjunto target_pairs, el cual indica cómo generar el conjunto train_labels.

Los conjuntos train y train_labels solo cuentan con variables flotantes y un índice de tipo entero, mientras que target_pairs contiene variables tipo object y una tipo entero, las cuales dan la información de cómo generar train_labels.

La mayoría de las columnas útiles tenían valores faltantes, pero estos no representaban más del 10% de los valores de cada columna.

Los modelos investigados que se usarán para predecir las series de tiempo serán: GARCH, SARIMA y SARFIMA. En el caso de los modelos SARIMA y SARFIMA no cumplieron con el supuesto de varianza estacionaria, pero se considerarán útiles si logran la mejor capacidad predictiva (véase cuadro 6).

Las columnas útiles del conjunto train cumple en su gran mayoría con buenos estadísticos para hacer modelos de volatilidad y la mayoría de los supuestos para los modelos SARIMA y SARFIMA (véase cuadro 5 y 6).

Como se observa en la figura 1 y 2, el aplicar la escala logarítmica facilita el manejo de la variación de los datos, dejando a todas las series en escalas muy similares. Además, como

esto se ve reflejado en la figura 3, donde el conjunto a predecir muestra un rango muy pequeño, variación muy controlada y medias cercanas a 0.

Se realizaron procesos de limpieza consistentes en cálculos, reemplazo por valor no nulo más próximo e interpolación en los conjuntos de train y train_labels. Realizando estas operaciones se lograron reemplazar todos los valores no nulos y se almacenaron los datos limpios en dos nuevos archivos csv llamados entrenamiento y entrenamiento_etiquetas.

Referencias

De Jesús-Gutiérrez, R. (2023). El uso de la volatilidad implícita en el modelado de la varianza condicional puede mejorar la predicción de la volatilidad y la estimación del VaR y CVaR. Economía: Teoría y Práctica, 58, 173–198.

Devianto, D., Wahyuni, E., Maiyastri, M., & Yollanda, M. (2024). The seasonal model of chili price movement with the effect of long memory and exogenous variables for improving time series model accuracy. Frontiers in Applied Mathematics and Statistics, 10, 1408381.

Li, X., Li, B., Wei, G., Bai, L. y Wei, Y. (2021). Return connectedness among commodity and financial assets during the COVID-19 pandemic: Evidence from China and the US. Resources Policy, 73, 102166.

López, F., Ortiz, E. y Cabello, A. (2009). Las interrelaciones de volatilidad y rendimientos entre los mercados de valores del TLCAN. Investigación Económica, 68(267), 83–114.

Mohommad, A., Raissi, M., Lee, K., & Fizzarotti, C. (2023). La volatilidad de precios de las materias primas reduce el crecimiento y aumenta las fluctuaciones de la inflación. Fondo Monetario Internacional.