Universidad del Valle de Guatemala
Ciencia de Datos, sección 10

Proyecto 2

Predicción de Commodities usando series temporales

Ricardo Rodríguez 18907
Karen Toledo 23692
Martín Pérez 23234
Ian Castellanos 22128

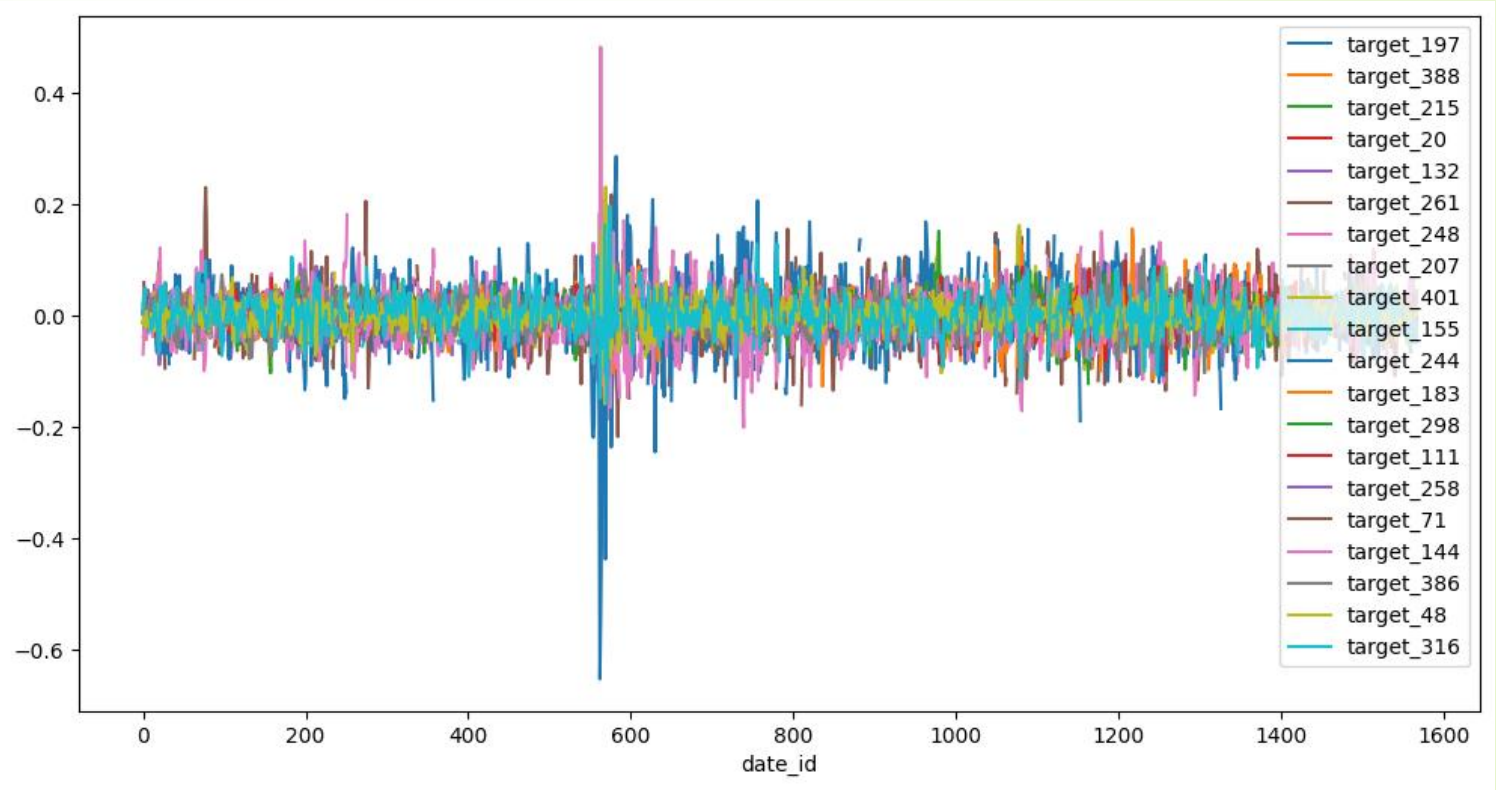


- Los mercados de commodities y activos financieros presentan alta volatilidad, lo que dificulta la predicción de sus rendimientos futuros.
- El modelado y predicción de estos cambios ha sido de interés para los inversionistas y académicos dado que la volatilidad manifiesta de diferentes formas.

EDA

Las etiquetas o targets se concentran alrededor de cero, presentan picos asociados con periodos de mayor volatilidad.

El problema requiere modelos de series temporales capaces de capturar dependencia temporal y cambios en la variabilidad.



DEFINICIÓN DEL RETO

Construir modelos de series temporales que permitan anticipar el comportamiento de cada activo usando:

train.csv

Precios, volúmenes y valores de commodities, acciones, divisas y futuros observados a través del tiempo.

train_labels

Resultados objetivo, llamados target_n que representar cambios entre periodos, como rendimientos logarítmicos.

target_pairs.csv

Diccionario que conecta cada target con una variable o par de variables de train.csv. Comparar rendimientos.



OBJETIVOS

1. **Generar modelos predictivos** para cada commodity presente en train.csv, mediante 3 tipos de modelos temporales.

2. **Determinar la validez del mejor modelo** para cada commodity, mediante la evaluación de los supuestos estadísticos del modelo.

3. **Cuantificar la pérdida de capacidad predictiva del mejor modelo**, mediante la evolución del error predictivo a través del tiempo de predicción.

Datos originales → Limpieza → Modelos → Evaluación → Mejor modelo

DATOS DE ENTRENAMIENTO

Se partió de los datos limpios generados en la etapa de limpieza.

Se usaron 106 variables útiles de 557 de train.csv, **19%** necesarias para calcular o explicar los targets que se querían predecir.

Se aplicó transformación logarítmica para trabajar con cambios relativos.

Se dividieron las series en:

ENTRENAMIENTO

89.9% 1764 observaciones

PRUEBA

10.1% 197 observaciones







MODELOS ENTRENADOS

	MODELO	¿QUÉ MODELA?	¿POR QUÉ SE USÓ?
1	SARIMA	La evolución temporal	Algunas series pueden tener autocorrelación y comportamiento repetitivo en el tiempo
2	SARFIMA	La memoria larga	Algunas series financieras pueden tener dependencia persistente a largo plazo
3	GARCH	La volatilidad	Los commodities y activos financieros suelen tener varianza cambiante en el tiempo






Supuestos de modelos

Supuestos de SARIMA y SARFIMA

- La serie transformada debe ser estacionaria.
- Los residuos deben tener media cercana a cero.
- Los residuos no deben presentar autocorrelación.
- La varianza de los residuos debe ser constante.
- Los residuos deberían aproximarse a una distribución normal.
- Las raíces AR y MA deben indicar estabilidad.

Supuestos de GARCH

- Los residuos estandarizados deben tener media cero.
- No debe quedar autocorrelación lineal.
- No debe quedar autocorrelación en los residuos al cuadrado.
- No debe existir efecto ARCH remanente.
- La distribución seleccionada debe ajustarse a los residuos.
- El modelo debe converger.
- La persistencia de la volatilidad debe ser menor que uno.

Pruebas utilizadas

Supuesto	Prueba
Estacionariedad	ADF y KPSS
Media cero	Prueba t
Autocorrelación	Ljung–Box
Normalidad	Jarque–Bera
Heterocedasticidad	ARCH-LM
Distribución GARCH	PIT y Kolmogórov–Smirnov
Estabilidad	Raíces AR y MA
Persistencia	Suma de parámetros ARCH y GARCH

Supuestos de SARIMA

- El diagnóstico SARIMA disponible incluye 52 modelos correspondientes a acciones estadounidenses.

Supuesto	Evaluados	Cumplen	No cumplen	Cumplimiento (%)
Ausencia de autocorrelación	52	52	0	100
Normalidad de residuos	52	0	52	0
Homocedasticidad	52	0	52	0

- Los modelos SARIMA logran capturar la dependencia temporal, pero sus residuos continúan mostrando no normalidad y heterocedasticidad. Por ello, SARIMA explica la media de las series, pero no representa completamente su volatilidad.

Supuestos de SARFIMA

- Se diagnosticaron 29 modelos SARFIMA.

Supuesto	Evaluados	Cumplen	No cumplen	Cumplimiento (%)
Media cero	29	25	4	86.21
Residuos como ruido blanco	29	3	26	10.34
Normalidad	29	0	29	0
Homocedasticidad	29	0	29	0
Estacionariedad (ADF y KPSS)	29	0	29	0
Estabilidad de raices	29	29	0	100

- SARFIMA presenta estabilidad estructural y, en la mayoría de los casos, residuos con media cero. Sin embargo, persisten autocorrelación, heterocedasticidad y desviaciones importantes respecto a la normalidad.

Supuestos de GARCH

- Se diagnosticaron 25 modelos GARCH.

GARCH fue la familia con mayor cumplimiento conjunto de los supuestos relacionados con la volatilidad. No obstante, algunos modelos conservaron dependencia en los residuos al cuadrado o presentaron problemas de convergencia.

Supuesto	Evaluados	Cumplen	No cumplen	Cumplimiento (%)
Media cero	25	22	3	88
Sin autocorrelación lineal	25	21	4	84
Sin autocorrelación en cuadrados	25	15	10	60
Sin efecto ARCH remanente	25	20	5	80
Distribución adecuada	25	21	4	84
Convergencia	25	20	5	80
Persistencia menor que uno	25	25	0	100

Cuadros de métricas (no simulado)

- Resultados obtenidos de las 106 filas válidas del archivo principal:

Modelo ganador	Series ganadas	MAE promedio	MAE mediana	MAE mínimo	MAE máximo
SARIMA	52	0,0593	0,0467	0,0085	0,2441
SARFIMA	29	0,0606	0,0368	0,0105	0,2005
GARCH	25	0,0843	0,0588	0,0112	0,3915

- Interpretación
  - SARIMA fue el modelo ganador en la mayor cantidad de series y el menor MAR promedio.
  - SARFIMA obtuvo el menor MAE mediano entre sus series ganadoras y la serie con el menor MAE.
  - GARCH presentó mayor error promedio, aunque tuvo mejor cumplimiento de varios supuestos de volatilidad.
- Las métricas corresponden únicamente a las series donde cada familia fue seleccionada como ganadora; por tanto, no representan una comparación balanceada de los tres modelos sobre exactamente las mismas series.

Cuadros de métricas (Simulado)

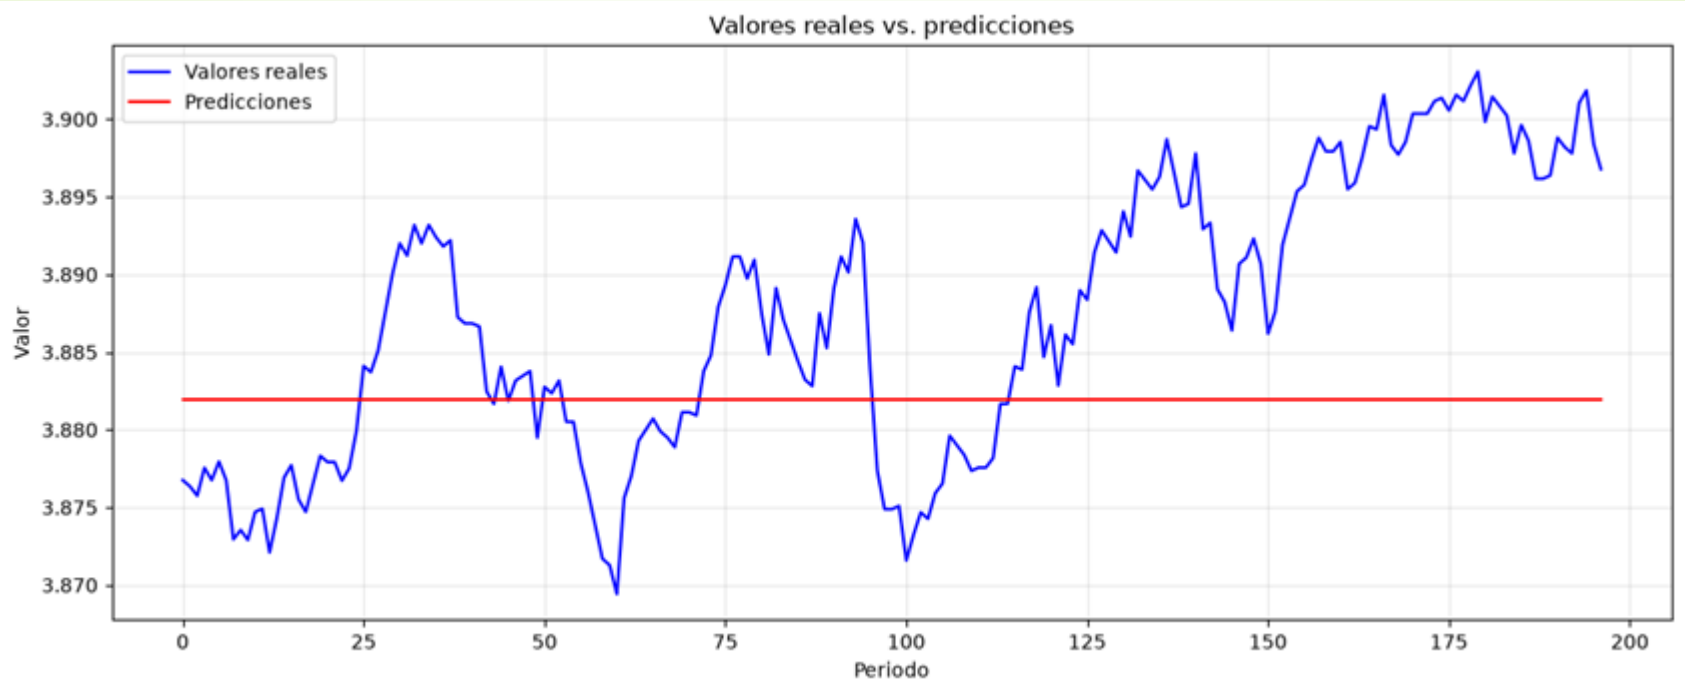
Series (MAE)

Estadístico	Valor
Mínimo	0.0147
Q1	0.0584
Mediana	0.1258
Q3	0.2621
Máximo	0.7745
Media	0.1700
Desviación estándar	0.1443

Etiquetas (MAE)

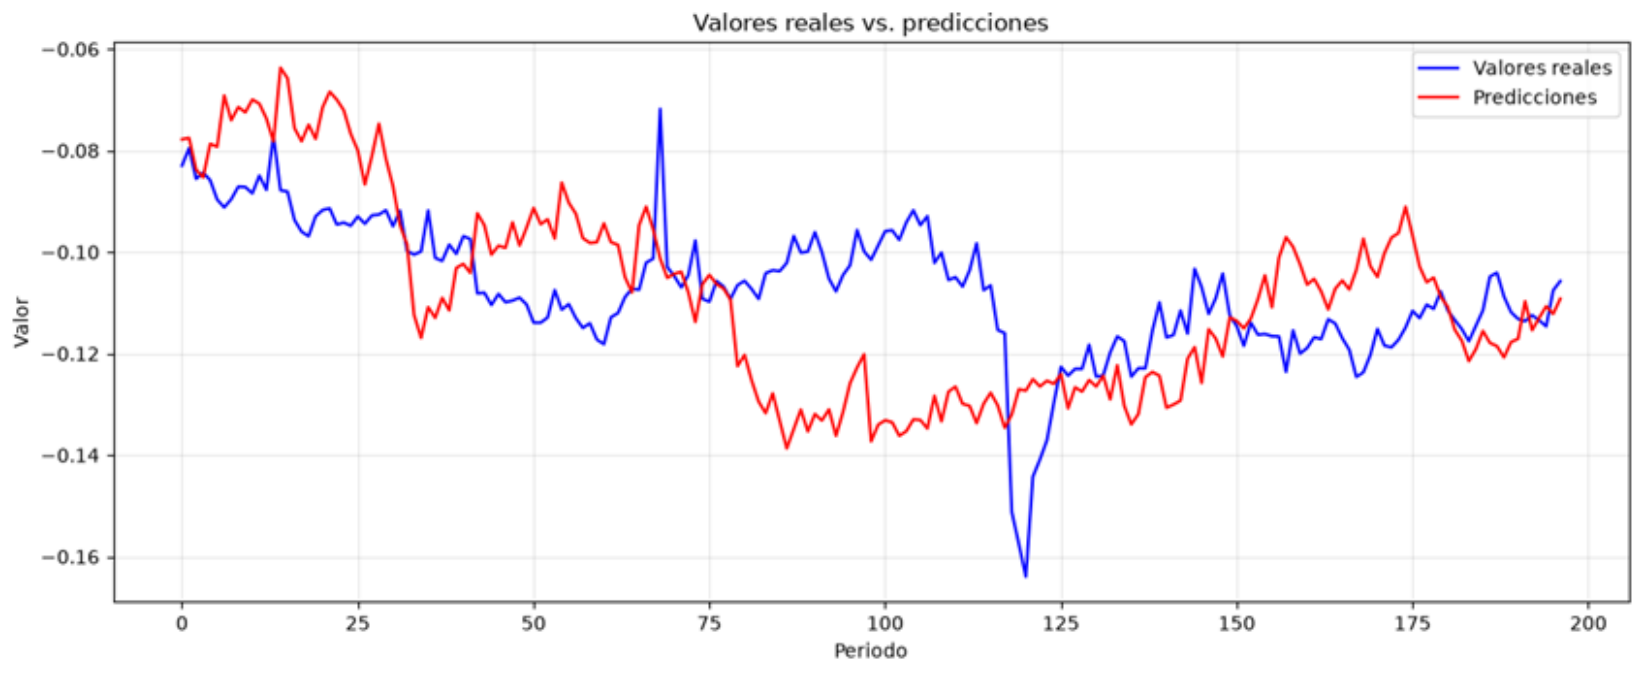
Estadístico	Valor
Mínimo	0.0089
Q1	0.0299
Mediana	0.0797
Q3	0.1310
Máximo	0.3222
Media	0.0855
Desviación estándar	0.0567

Gráfica de la mejor serie (normal)



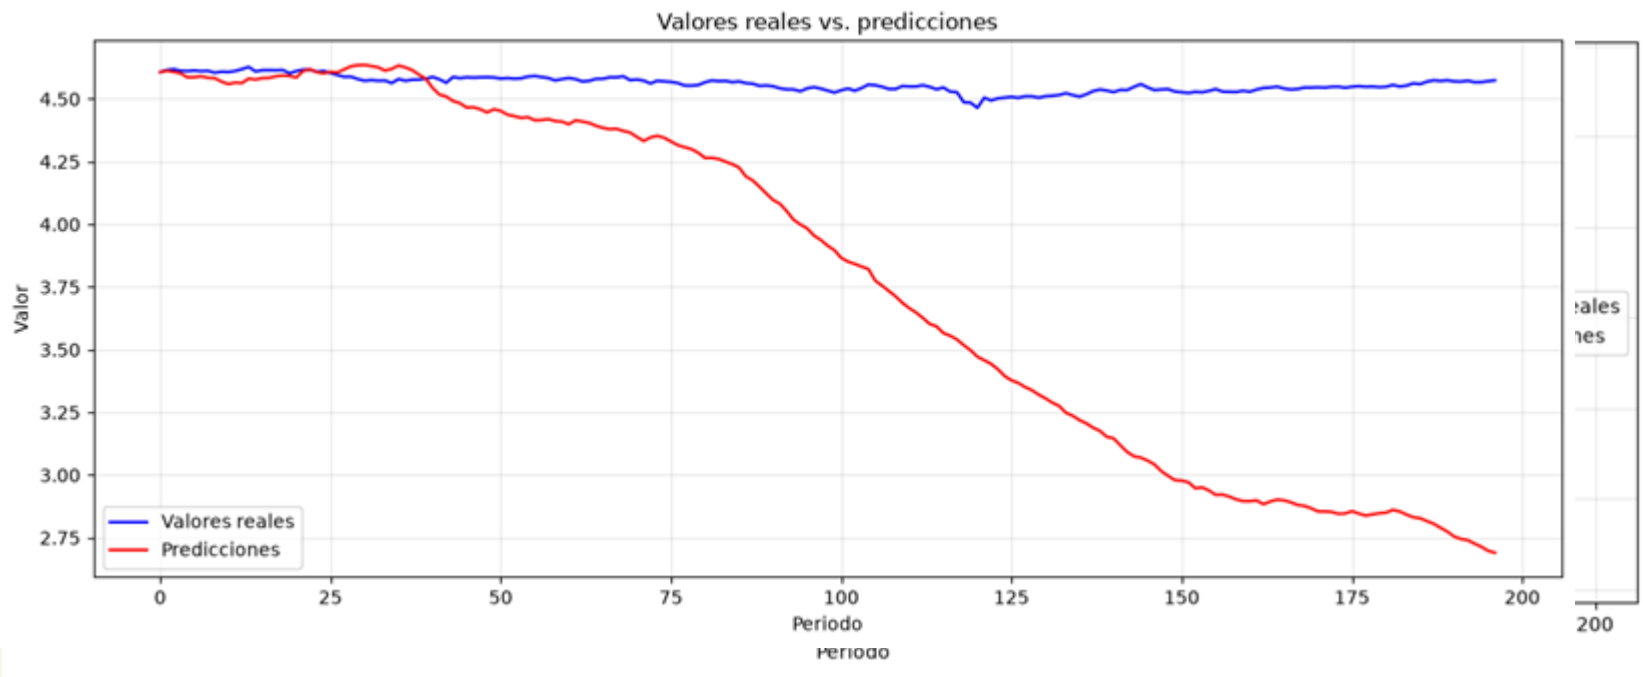
- El mejor resultado corresponde al modelo SARIMA aplicado a US_Stock_BNDX_adj_close, con MAE de 0.0085. Podemos observar que solo predice el valor esperado.

Gráfica de la mejor serie (simulada)



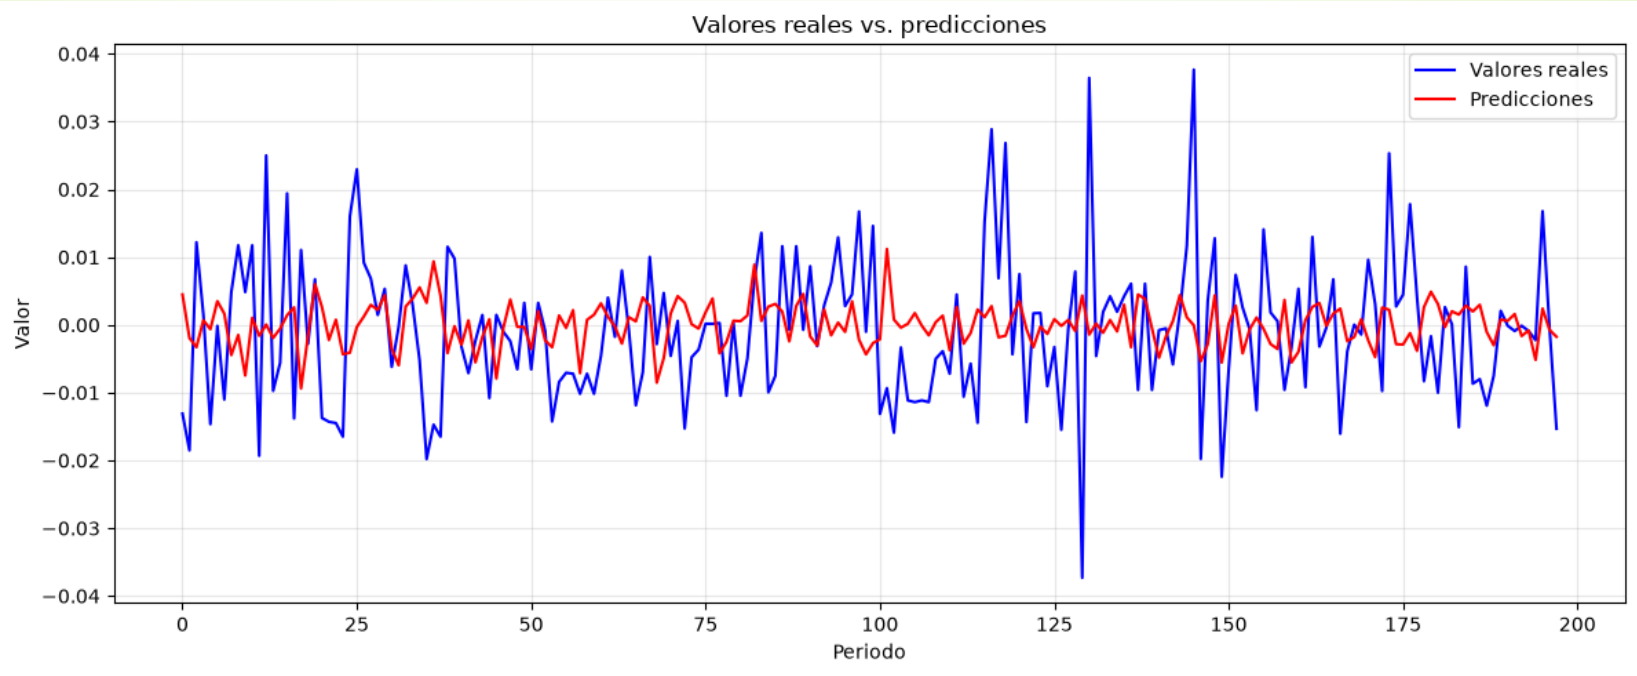
- El mejor resultado corresponde al modelo SARFIMA aplicado a FX_AUDCAD, con MAE de 0.0147. Podemos observar un buen ajuste al inicio y al final del modelo, con complicaciones en las predicciones de en medio.

Gráfica de la peor serie (simulada)



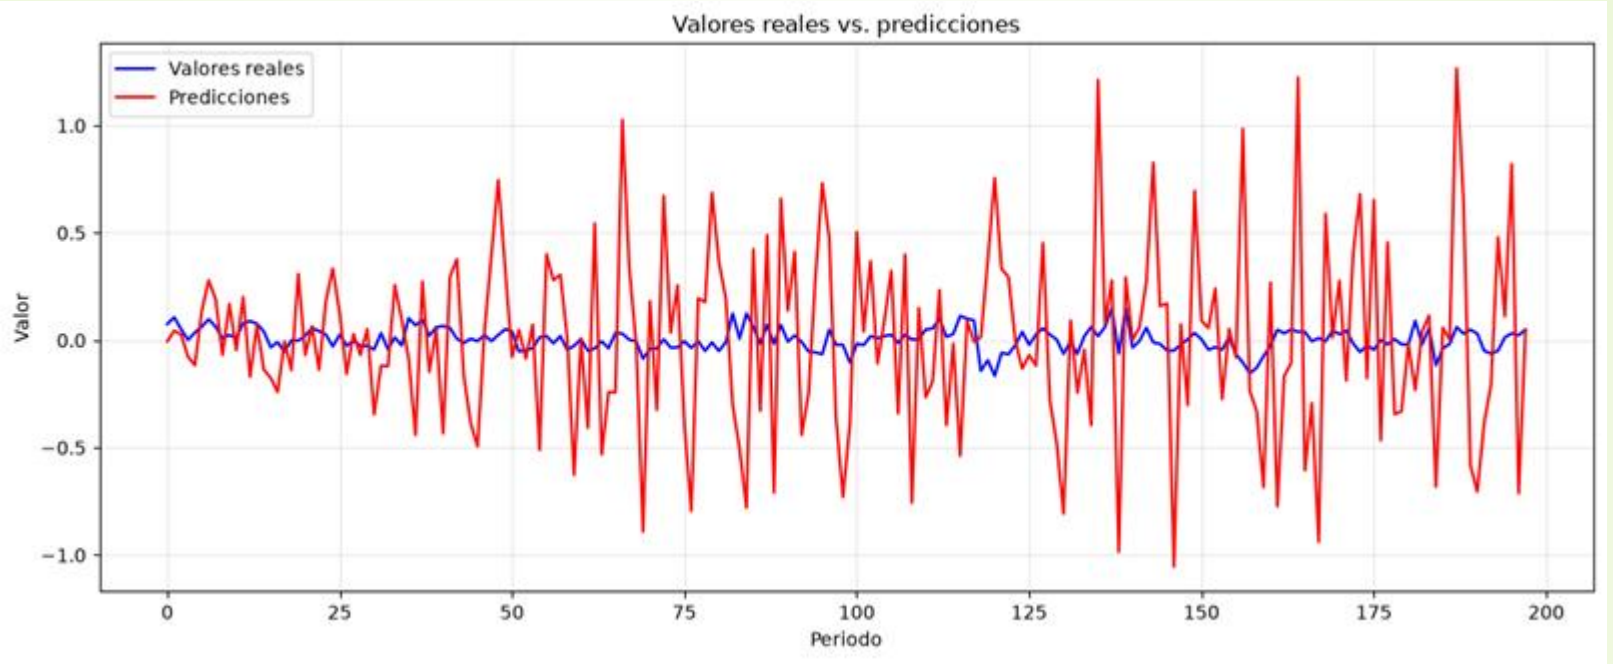
- El mejor resultado corresponde al modelo SARFIMA aplicado a FX_AUDJPY, con MAE de 0.7745. Al inicio logra predecir muy bien, pero después de, aproximadamente, 35 predicciones, el modelo empeora y se separa completamente de los datos reales.

Gráfica de la mejor etiqueta (simulada)



- El mejor resultado corresponde a target_68, con MAE de 0.0089. El modelo no logra predecir la intensidad de los picos, pero el ajuste en la tendencia es bueno.

Gráfica de la peor etiqueta (simulada)



- El mejor resultado corresponde a target_276, con MAE de 0.3222. El modelo no logra predecir la intensidad de los picos y se queda muy corto en la variación

Conclusiones

- SARIMA fue el modelo ganador más frecuente, con 52 de las 106 series.
- SARFIMA presentó el menor MAE mediano y la serie con el menor MAE.
- GARCH mostró el mejor cumplimiento general de los supuestos relacionados con la volatilidad, pero obtuvo el mayor MAE promedio.
- Ninguno resultó superior en todos los aspectos: SARIMA y SARFIMA fueron más competitivos en predicción, mientras que GARCH representó mejor la varianza condicional.
- Ninguno resultó superior en todos los aspectos: SARIMA y SARFIMA fueron más competitivos en predicción, mientras que GARCH representó mejor la varianza condicional.
- Ningún tipo de modelo cumplió con todos los supuestos, pero los de tipo GARCH tuvieron el mejor porcentaje de cumplimiento.
- Los modelos simulados, generaron mejores ajustes en las series originales que los modelos normales, esto se puede observar al comparar el mejor modelo normal con el mejor simulado.
- Las etiquetas simuladas no logran representar adecuadamente la intensidad de los picos, pero se ajustan adecuadamente al valor esperado.

Referencias

- De Jesús-Gutiérrez, R. (2023). El uso de la volatilidad implícita en el modelado de la varianza condicional puede mejorar la predicción de la volatilidad y la estimación del VaR y CVaR. Economía: Teoría y Práctica, 58, 173–198.
- Devianto, D., Wahyuni, E., Maiyastri, M., & Yollanda, M. (2024). The seasonal model of chili price movement with the effect of long memory and exogenous variables for improving time series model accuracy. Frontiers in Applied Mathematics and Statistics, 10, 1408381.
- Li, X., Li, B., Wei, G., Bai, L. y Wei, Y. (2021). Return connectedness among commodity and financial assets during the COVID-19 pandemic: Evidence from China and the US. Resources Policy, 73, 102166.
- López, F., Ortiz, E. y Cabello, A. (2009). Las interrelaciones de volatilidad y rendimientos entre los mercados de valores del TLCAN. Investigación Económica, 68(267), 83–114.
- Mohommad, A., Raissi, M., Lee, K., & Fizzarotti, C. (2023). La volatilidad de precios de las materias primas reduce el crecimiento y aumenta las fluctuaciones de la inflación. Fondo Monetario Internacional.