

PREDICCIÓN DE COMMODITIES USANDO SERIES TEMPORALES



CONTENIDO

- PROBLEMA
- OBJETIVOS
- DATOS
- LIMPIEZA
- ANÁLISIS EXPLORATORIO (EDA)
- HALLAZGOS
- CONCLUSIONES Y SIGUIENTES PASOS
- REFERENCIAS



SITUACIÓN PROBLEMÁTICA

- Los commodities son conocidos por su alta volatilidad → un modelo de volatilidad es una opción viable para predecir (Mohammad et al., FMI, 2023).
- En los últimos años los mercados vivieron volatilidad extremadamente alta por la crisis de 2008 y la pandemia de Covid-19.
- Modelar y predecir la volatilidad a corto y largo plazo es de principal interés para inversionistas y académicos (De Jesús-Gutiérrez, 2023).

¿Es posible predecir rendimientos/volatilidad de series de commodities con modelos de series de tiempo cumpliendo sus supuestos?

MODELOS CANDIDATOS:

GARCH

modela la volatilidad (varianza condicional). Se basa en que la varianza no es estacionaria.

SARIMA

modela dependencia temporal y patrones estacionales.

SARFIMA

añade memoria larga (dependencia de largo plazo), útil cuando la influencia de observaciones pasadas disminuye lentamente.

Los tres modelos atacan aspectos distintos (volatilidad vs. dependencia temporal), y el EDA nos dirá cuáles supuestos se cumplen para elegir.

OBJETIVOS

GENERAL

Generar modelos predictivos para cada Commodity del conjunto train.csv usando 3 tipos de modelos temporales.

ESPECÍFICOS

1 Evaluar cumplimiento de supuestos estadísticos del mejor modelo.

Se responde con pruebas estadísticas.

2 Cuantificar la pérdida predictiva con la evolución del error a través del horizonte de predicción.

Se responde con la evolución del error (MAE/RMSE) en el tiempo.

DESCRIPCIÓN DE LOS DATOS

ARCHIVO	DIMENSIONES	CONTENIDO
train	1961 × 558	Datos de commodities a través de 1961 unidades de tiempo. Precios e indicadores (todos float64 a excepción del índice)
train_labels	1961 × 425	Rendimientos logarítmicos a distintos lags (todos float64 a excepción del índice)
target_pairs	424 × 3	Define cada target: target, lag, pair

train_labels = rendimientos logarítmicos calculados con target_pairs sobre train.
A partir de aquí, se dejará de contar el índice de train y train_labels

LIMPIEZA Y PREPROCESAMIENTO

train tiene 557 columnas, pero no todas sirven.

PROCESO EN LIMPIEZA.IPYNB:

1. Separar solo las 106 columnas útiles de train.
2. Aplicar escala logarítmica.
3. Recalcular nulos de train_labels con la fórmula de target_pairs → 66,977.
4. Rellenar nulos del inicio y final de train con el valor no nulo más próximo → 36.
5. Igual en train_labels → 319.
6. Interpolar nulos de train → 4,919 → train sin nulos.

7. Recalcular nulos restantes de train_labels
→ 20,107 → train_labels sin nulos.

Resultado: 0 valores nulos.
**Guardado en entrenamiento.csv
y entrenamiento_etiquetas.csv.**

EDA – ESTADÍSTICA DESCRIPTIVA

106 de las 557 variables de train (quitando el índice) son útiles para generar los targets.

Después de aplicar escala logarítmica y diferenciación:

- Media y mediana se mantienen cercanas en todas las series.
- Todas presentan curtosis positiva.
- La dispersión mejora con el orden de diferenciación.
- El sesgo aumenta ligeramente con diferenciaciones superiores.

La transformación logarítmica homogeneiza la escala de las series y facilita su comparación.

Archivo	Columnas con nulos	Máximo	Mínimo
train (557)	519	1,713	51
train_labels (424)	422	370	86
target_pairs	0	0	0

EDA – SUPUESTOS Y SERIES


Criterio	Dif. 1	Dif. 2	Dif. 3	Dif. 4
No estacionarias en media	1	1	2	2
No estacionarias en varianza	106	106	106	106
Sin volatilidad temporal*	0	0	0	0
Problemas ACF	1	0	0	0
Problemas PACF	1	0	0	0
Sin estacionalidad detectada*	86	96	101	88

La media es estacionaria en casi todas las series, pero ninguna de las 106 presenta estacionariedad de varianza. Esto favorece explorar modelos de volatilidad como GARCH.

EDA – OUTLIERS Y DISTRIBUCIÓN

Los targets se concentran alrededor de 0, pero presentan episodios extremos.

- Los rendimientos muestran un rango generalmente reducido.
- Las medias se encuentran cercanas a cero.
- Existen picos positivos y negativos aislados.
- Estos movimientos extremos son relevantes al estudiar volatilidad y no deben eliminarse automáticamente como errores.



HALLAZGOS

GARCH (VOLATILIDAD).

Candidato fuertemente justificado

Las 106 series incumplen estacionariedad de varianza y muestran comportamiento compatible con el análisis de volatilidad.

SARIMA

La estacionariedad de media se cumple en prácticamente todas las series y casi todas las series presentaron autocorrelación significativa.

SARFIMA (DEPENDENCIA

TEMPORAL/ESTACIONALIDAD)

Permite evaluar dependencias temporales persistentes que una diferenciación convencional podría no capturar.

El EDA justifica evaluar los tres modelos, pero no permite todavía determinar cuál tendrá mayor capacidad predictiva.

CONCLUSIONES Y SIGUIENTES PASOS

1. De las 557 variables originales, únicamente 106 son necesarias para generar los targets.

2. La escala logarítmica reduce las diferencias de escala entre las series y facilita su análisis.

3. Los nulos fueron tratados mediante reconstrucción a partir de target_pairs, valores próximos e interpolación, obteniendo conjuntos finales sin valores faltantes.

4. La mayoría de las series cumple estacionariedad de media, pero las 106 incumplen estacionariedad de varianza, justificando explorar modelos de volatilidad.

5. El EDA respalda continuar con GARCH, SARIMA y SARFIMA y comparar empíricamente su capacidad predictiva.

Siguientes pasos:

Ajustar los 3 modelos

→ Validar supuestos

→ Comparar MAE/RMSE

→ Evaluar degradación del error según horizonte

REFERENCIAS

- De Jesús-Gutiérrez, R. (2023). Economía: Teoría y Práctica, 58, 173–198.
- Devianto, D., Wahyuni, E., Maiyastri, M., & Yollanda, M. (2024). Frontiers in Applied Mathematics and Statistics, 10, 1408381.
- Li, X., Li, B., Wei, G., Bai, L., & Wei, Y. (2021). Resources Policy, 73, 102166.
- López, F., Ortiz, E. y Cabello, A. (2009). Investigación Económica, 68(267), 83–114.
- Mohommad, A., Raissi, M., Lee, K., & Fizzarotti, C. (2023). Fondo Monetario Internacional.